

La Vida Secreta de las Setas: Cómo los Datos Salvan Vidas



Imagínate: estás en el monte con una cesta en la mano. A tu alrededor, setas tentadoras. Una con un aroma agradable, otra con un sombrero vistoso. Pero una elección equivocada y tu cena se convierte en la última.

Durante siglos, la humanidad ha jugado con la naturaleza a la "ruleta rusa". Pero ahora tenemos una nueva arma: **los datos**. Bienvenido al mundo de la analítica micológica, donde cada línea de una tabla puede salvarte la vida.

Capítulo 1: Retratos Misteriosos del Reino Fúngico

Ante nosotros tenemos 8.124 "pasaportes" de setas, cada uno con 23 características: desde la forma del sombrero hasta el color de las esporas. Es como una base de datos del FBI, pero en lugar de delincuentes, aquí tenemos hongos. ¿Cuáles son mortalmente peligrosos y cuáles son perfectos para un guiso?

```
class cap-shape cap-surface cap-color bruises odor gill-attachment \
0      p          x          s          n          t          p          f
1      e          x          s          y          t          a          f
2      e          b          s          w          t          l          f
3      p          x          y          w          t          p          f
4      e          x          s          g          f          n          f

gill-spacing gill-size gill-color ... stalk-surface-below-ring \
0            c          n          k          ...          s
1            c          b          k          ...          s
2            c          b          n          ...          s
3            c          n          n          ...          s
4            w          b          k          ...          s
```

El primer vistazo a los datos produce la sensación de estar leyendo un texto rúnico: Pero en estos símbolos se esconde el código de la vida y la muerte:

- **p** — poisonous, venenosa
- **e** — edible, comestible

Cada característica es una pista.

Capítulo 2: Investigación Detectivesca

¿Qué sabemos de nuestros "sospechosos"?

- **23 características**, pero una (veil-type) resultó ser falsa: siempre igual, como un pase falsificado. La eliminamos.
- En el campo stalk-root hay **2.480 valores perdidos**. ¿Desaparecidos en combate? Pero el análisis revela: la ausencia de datos también es una pista. Los valores perdidos aparecen más frecuentemente en setas venenosas.

Visualización de las pistas:



El gráfico muestra claramente que "la nada" también es una señal. La naturaleza no tolera el vacío.

Capítulo 3: Cifrados y Códigos

Las características categóricas son como mensajes en el idioma misterioso de las setas. Las desciframos mediante **One-Hot Encoding**, transformando 22 características en **116 claves numéricas**. Es como traducir el lenguaje fúngico al lenguaje de las máquinas.


Dividimos los datos:

- **70%** (5.443 setas) — entrenamiento para el modelo
- **30%** (2.681 setas) — examen con situaciones reales

Capítulo 4: Las Gafas Mágicas del PCA

¿Cómo vislumbrar la verdad a través de 116 dimensiones? Nos ponemos las gafas mágicas del **PCA** y comprimimos el mundo a dos componentes principales. Es como hacer una radiografía al universo de las setas.

En el mapa 2D se produce el milagro:



- Comestibles (rojas) — en "pueblos" compactos
- Venenosas (azules) — separadas, como en cuarentena

Una línea de demarcación nítida entre ambas

Pero hay traidores:

- Puntos azules en zona roja — **falsa seguridad**
- Rojos en zona azul — **falsas acusaciones**

Nuestro objetivo: reducir el número de estos errores trágicos.

Capítulo 5: El Jurado — Comparación de Métodos de Investigación

Como un detective compara versiones, nosotros confrontamos tres enfoques:

1. Random Forest — Las Fuerzas Especiales Micológicas

Cómo funciona:

- 100 árboles-detective
- Cada uno analiza un conjunto aleatorio de pistas
- Decisión final por votación

Resultados: Precisión: 100% (datos nuevos)

Ventajas:


- Capta las más sutiles señales venenosas
- No requiere preparación manual

2. PCA + Clustering — El Cartógrafo del Mundo Fúngico

Cómo funciona:

1. PCA — crea el mapa
2. KMeans — agrupa en zonas

Resultados:



- 6 clústeres bien definidos (clústeres 0, 2, 3, 5, 6, 7 y 8):
 - ✓ Seguros (clústeres 3, 5, 7 y 8)
 - ✓ Peligrosos (clústeres 0, 2, 6)
 - ✓ Sospechosos (clústeres 1, 4, 9)

Insights:

- 72% de las setas correctamente clasificadas
- 28% son "espías" que requieren atención de un experto

3. PCA + Random Forest — La Unidad de Élite

Cómo funciona:

- ✓ PCA reduce la dimensionalidad (a 8 características en lugar de 116)
- ✓ Random Forest clasifica los datos simplificados

Resultados: Precisión: 100%

Tabla Comparativa:

Método	Precisión	Interpretabilidad
Random Forest puro	100%	Media
Clustering	78.0%	Alta
PCA + Random Forest	100%	Media

¿La Última Cena de Setas?

Los datos no son solo números. Son tu inmunidad digital en un mundo lleno de trampas naturales.

"La seta más peligrosa es la que no supiste reconocer."

Los datos son tu inmunidad digital."

— Detective Micológico, 2025, Factoria F5: 

Juan Carlos Macias



Maryna Nalyvaiko

